

Reto de la semana

Un clasificador binario es aquel que nos permite etiquetar una observación dada como 0 o 1. La regresión logística es una técnica fundamental en aprendizaje automático que permite construir clasificadores binarios lineales a partir de unos datos de entrenamiento. En este reto, partiendo de unos datos de entrenamiento, construiremos la función que nos indica qué tan bueno es un clasificador, y la analizaremos usando descriptores como lo son su gradiente y Hessiana.

Regresión logística

La regresión logística es una técnica que nos permite obtener un clasificador lineal binario. Considere un dato de entrada $x = [x_1, x_2] \in \mathbb{R}^2$, y sea $z = [x, 1]^T$. Sea $w = [w_1, w_2, w_3]^T$ el vector de parámetros del clasificador. La clasificación de este dato se realiza a través de la siguiente regla:

Si $w^T z = w_1 x_1 + w_2 x_2 + w_3 > 0$, entonces x es clasificado como un dato de clase 1

Si $w^T z = w_1 x_1 + w_2 x_2 + w_3 < 0$, entonces x es clasificado como un dato de clase 0.

La función que mide qué tan bueno es el clasificador con parámetros w para clasificar sobre m datos de entrenamiento (denominada función de pérdida) se define a través de la siguiente ecuación:

$$f(w) = -\frac{1}{m} \sum_{i=1}^m t_i \log y_i + (1 - t_i) \log(1 - y_i)$$

donde:

- $x^{(i)}$: i -ésimo dato de entrenamiento. Es un número real en este caso.
- $z^{(i)} = [x^{(i)}, 1]^T$.

- t_i : es la clase verdadera del i -ésimo dato de entrenamiento. Es 0 o 1.
- $y_i = \frac{1}{1+e^{-w^T z^{(i)}}}$ es la sigmoide o función logística.

Entre más pequeño el valor de $f(w)$, mejor es el w para definir la regla de clasificación. Es importante aclarar que la notación $x^{(i)}$ no significa que x esté "elevado" a la i . Es una forma de mostrar que éste es el i -ésimo dato x .

Se sabe que el gradiente de f está definido por:

$$\nabla f(w) = \frac{1}{m} \sum_{i=1}^m (y_i - t_i) z^{(i)}$$

Y la matriz Hessiana está dada por:

$$F(w) = \frac{1}{m} \sum_{i=1}^m y_i (1 - y_i) (z^{(i)})(z^{(i)})^T .$$

Implementación de la función de pérdida de la regresión logística

Considere el archivo adjunto `breastCancer`. Esta es una base de datos real que contienen información sobre las características extraídas del núcleo de células epiteliales mamarias y otros atributos de células de mama, recolectadas a través del análisis de imágenes digitalizadas de biopsias de mama. Este conjunto de datos presenta **569 observaciones con 2 características** (features) cada una, que corresponden a medidas resultado del análisis de la imagen digital mamaria. Estas características corresponden a 2 propiedades que se calculan para cada núcleo de célula observada en la imagen. La variable `pronostic` contiene las etiquetas de cada una de estas observaciones, donde 1 es si la muestra tiene malignidad, y 0 si no es una muestra maligna. Esta base de datos es la que contiene los $x^{(i)}$ con sus respectivos t_i para el entrenamiento del clasificador.

Reto de la semana | Gradiente y Hessiana en la regresión logística

- a) Lea los datos del archivo adjunto `breastCancer`, y grafique un scatter plot con cada una de las observaciones (es decir, cada $x^{(i)}$). Defina un código de colores de tal manera que las observaciones de la clase 0 tengan un color, y las observaciones de la clase 1 tengan otro color.
- b) Escriba una porción de código que reciba el vector $w = [w_1, w_2, w_3]^T$, y grafique la recta $w_1x_1 + w_2x_2 + w_3 = 0$ sobre el scatter plot del punto a).
- c) Usando los datos del archivo adjunto `breastCancer`, defina una función en Python que reciba un vector $w = [w_1, w_2, w_3]^T$ y los datos de entrenamiento (es decir, los $x^{(i)}$ con sus respectivos t_i), y calcule $f(w)$. Esta función nos permite cuantificar qué tan bueno es ese w para clasificar los datos de entrenamiento. Recuerde que entre más pequeño es el valor de $f(w)$, mejor es w para realizar la clasificación en los datos de entrenamiento.
- d) Considere los siguientes candidatos w :

w_1	w_2	w_3
0.0603	4.0364	1.3192
-1.345	3.597	-0.588
0.0603	1.000	0.502

Cada fila de la tabla corresponde a un candidato w a clasificador. Para cada uno de estos valores, calcule $f(w)$ usando la función en c).

- e) Usando el código en b), para cada w de la tabla en d), grafique la recta asociada sobre el scatter plot de los datos. Analice los resultados a través de una inspección visual de la recta sobre los datos, y de los valores correspondientes de $f(w)$. Aquí, note que w asociados a valores menores de $f(w)$ genera rectas con mejor separación de los datos.

Reto de la semana | Gradiente y Hessiana en la regresión logística

- f) Implemente una función en Python que reciba w , y devuelva el gradiente y la Hessiana. Para cada w en d), calcule el gradiente y la Hessiana. Aquí, note que la magnitud del gradiente es menor para aquellos w que tienen una mejor capacidad de clasificación. También, observe que la Hessiana siempre es positiva definida para todos los valores de w (es decir, sus valores propios siempre son mayores que cero).



Universidad de
los Andes

Colombia

© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
