

Reto de la semana

Un clasificador binario es aquel que nos permite etiquetar una observación dada como 0 o 1. La regresión logística es una técnica fundamental en aprendizaje automático que permite construir clasificadores binarios lineales a partir de unos datos de entrenamiento. En este reto, usando la función de pérdida construida la semana pasada, resolveremos un problema de optimización para encontrar el clasificador que minimiza esta función.

Regresión logística

La regresión logística es una técnica que nos permite obtener un clasificador lineal binario. Considere un dato de entrada $x = [x_1, x_2] \in \mathbb{R}^2$, y sea $z = [x, 1]^T$. Sea $w = [w_1, w_2, w_3]^T$ el vector de parámetros del clasificador. La clasificación de este dato se realiza a través de la siguiente regla:

Si $w^T z = w_1 x_1 + w_2 x_2 + w_3 > 0$, entonces x es clasificado como un dato de clase 1

Si $w^T z = w_1 x_1 + w_2 x_2 + w_3 < 0$, entonces x es clasificado como un dato de clase 0.

La función que mide qué tan bueno es el clasificador con parámetros w para clasificar sobre m datos de entrenamiento (denominada función de pérdida) se define a través de la siguiente ecuación:

$$f(w) = -\frac{1}{m} \sum_{i=1}^m t_i \log y_i + (1 - t_i) \log(1 - y_i)$$

donde:

- $x^{(i)}$: i -ésimo dato de entrenamiento. Es un número real en este caso.
- $z^{(i)} = [x^{(i)}, 1]^T$.
- t_i : es la clase verdadera del i -ésimo dato de entrenamiento. Es 0 o 1.

- $y_i = \frac{1}{1+e^{-w^T z^{(i)}}}$ es la sigmoide o función logística.

Entre más pequeño el valor de $f(w)$, mejor es el w para definir la regla de clasificación. Es importante aclarar que la notación $x^{(i)}$ no significa que x esté “elevado” a la i . Es una forma de mostrar que ése es el i -ésimo dato x .

Formulando y solucionando el problema de optimización

Considere el archivo adjunto `breastCancer`. Esta es una base de datos real que contienen información sobre las características extraídas del núcleo de células epiteliales mamarias y otros atributos de células de mama, recolectadas a través del análisis de imágenes digitalizadas de biopsias de mama. Este conjunto de datos presenta **569 observaciones con 2 características** (features) cada una, que corresponden a medidas resultado del análisis de la imagen digital mamaria. Estas características corresponden a 2 propiedades que se calculan para cada núcleo de célula observada en la imagen. La variable `pronostic` contiene las etiquetas de cada una de estas observaciones, donde 1 es si la muestra tiene malignidad, y 0 si no es una muestra maligna. Esta base de datos es la que contiene los $x^{(i)}$ con sus respectivos t_i para el entrenamiento del clasificador.

- a) Considere el problema de optimización

$$\min_w f(w)$$

sujeto a $w \in \mathbb{R}^3$,

donde $f(w)$ se construye partir de los datos en `breastCancer`. Usando el código desarrollado en el reto anterior, solucione este problema de optimización usando algún `solver` de optimización como `minimize` de Scipy.

- b) Identifique el w encontrado después de resolver el proceso de optimización. Grafique la recta definida por ese w sobre el scatter plot de los datos.

Reto de la semana | Resolviendo el problema de optimización de la regresión logística

- c) Para ese w encontrado, calcule el valor de la función objetivo, el gradiente y la Hessiana.



Universidad de
los Andes

Colombia

© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
