

Reto de la semana

Un clasificador binario es aquel que nos permite etiquetar una observación dada como 0 o 1. La regresión logística es una técnica fundamental en aprendizaje automático que permite construir clasificadores binarios lineales a partir de unos datos de entrenamiento. En este reto, resolviendo el problema de optimización en retos anteriores, analizaremos la búsqueda de la solución del problema de optimización a la luz de las condiciones de un minimizador.

Regresión logística

La regresión logística es una técnica que nos permite obtener un clasificador lineal binario. Considere un dato de entrada $x = [x_1, x_2] \in \mathbb{R}^2$, y sea $z = [x, 1]^T$. Sea $w = [w_1, w_2, w_3]^T$ el vector de parámetros del clasificador. La clasificación de este dato se realiza a través de la siguiente regla:

Si $w^T z = w_1 x_1 + w_2 x_2 + w_3 > 0$, entonces x es clasificado como un dato de clase 1

Si $w^T z = w_1 x_1 + w_2 x_2 + w_3 < 0$, entonces x es clasificado como un dato de clase 0.

La función que mide qué tan bueno es el clasificador con parámetros w para clasificar sobre m datos de entrenamiento (denominada función de pérdida) se define a través de la siguiente ecuación:

$$f(w) = -\frac{1}{m} \sum_{i=1}^m t_i \log y_i + (1 - t_i) \log(1 - y_i)$$

donde:

- $x^{(i)}$: i -ésimo dato de entrenamiento. Es un número real en este caso.
- $z^{(i)} = [x^{(i)}, 1]^T$.
- t_i : es la clase verdadera del i -ésimo dato de entrenamiento. Es 0 o 1.

- $y_i = \frac{1}{1+e^{-w^T z^{(i)}}}$ es la sigmoide o función logística.

Entre más pequeño el valor de $f(w)$, mejor es el w para definir la regla de clasificación. Es importante aclarar que la notación $x^{(i)}$ no significa que x esté “elevado” a la i . Es una forma de mostrar que ése es el i -ésimo dato x .

Analizando el proceso de optimización

Considere el archivo adjunto `breastCancer`. Esta es una base de datos real que contienen información sobre las características extraídas del núcleo de células epiteliales mamarias y otros atributos de células de mama, recolectadas a través del análisis de imágenes digitalizadas de biopsias de mama. Este conjunto de datos presenta **569 observaciones con 2 características** (features) cada una, que corresponden a medidas resultado del análisis de la imagen digital mamaria. Estas características corresponden a 2 propiedades que se calculan para cada núcleo de célula observada en la imagen. La variable `pronostic` contiene las etiquetas de cada una de estas observaciones, donde 1 es si la muestra tiene malignidad, y 0 si no es una muestra maligna. Esta base de datos es la que contiene los $x^{(i)}$ con sus respectivos t_i para el entrenamiento del clasificador.

- a) Considere el problema de optimización

$$\min_w f(w)$$

sujeto a $w \in \mathbb{R}^3$,

donde $f(w)$ se construye partir de los datos en `breastCancer`. Usando el código desarrollado en el reto anterior, solucione este problema de optimización usando algún `solver` de optimización como `minimize` de Scipy.

- b) Las funciones como `minimize` de Scipy realizan un proceso iterativo en el que se evalúan posibles candidatos w en cada iteración, hasta llegar a una solución definitiva. Escriba un

Reto de la semana | Minimizador local del problema de regresión logística

código que rastree cada uno de estos candidatos w a solución explorados por el *solver* que resuelve el problema de optimización. En particular, el argumento *callback* de *minimize* permite hacer ese rastreo.

- c) Grafique $f(w)$ vs. el número de iteraciones, y observe la evolución de la función objetivo en cada una de las iteraciones.
- d) Grafique $\|\nabla f(w)\|_2$ vs. el número de iteraciones, y observe la evolución del gradiente de la función objetivo en cada una de las iteraciones.
- e) Calcule la Hessiana en el w solución al problema de optimización, y evalúe su positividad. Use las condiciones de un minimizador para concluir sobre esta solución.

Hint: Se puede demostrar que f es una función convexa sobre $\mathbb{R}^3$.



Universidad de
los Andes

Colombia

© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
