

Reto de la semana

Un clasificador binario es aquel que nos permite etiquetar una observación dada como 0 o 1. La regresión logística es una técnica fundamental en aprendizaje automático que permite construir clasificadores binarios lineales a partir de unos datos de entrenamiento. En este reto, usando el código desarrollado en retos anteriores, realizaremos la búsqueda de la solución al problema de regresión logística usando el algoritmo de descenso de gradiente.

Descenso de gradiente

El método de descenso de gradiente es un algoritmo iterativo con el que intentamos buscar los parámetros $w \in \mathbb{R}^n$ que minimicen una función objetivo $f(w)$. Es decir, queremos encontrar w tal que la función $f(w)$ sea lo más pequeña posible, y el método de descenso de gradiente nos ayuda a resolver este problema de búsqueda. El método de Newton parte de una condición inicial de w , es decir, un punto de partida, y de ahí empieza a buscar posibles opciones que minimicen la función objetivo.

Sea w_0 el punto inicial con el que el método de descenso de gradiente va a empezar a buscar. Sea $f(w)$ la función a minimizar, y $\nabla f(w)$ el gradiente de la función evaluado en w . El pseudo algoritmo del método de descenso de gradiente es el siguiente:

```
// Inicialización
k = 0           // Contador de iteraciones o pasos en la búsqueda
w = w0        // Punto actual
Definir  $\alpha$    // Tamaño del salto de gradiente, conocido como tasa de aprendizaje
```

Reto de la semana | Descenso de gradiente para resolver el problema de regresión logística

```
MIENTRAS k < max_iter: // Ciclo que se mantiene durante un número máximo de iteraciones
    // Paso 1: Calcular el gradiente en el punto actual
    g = ∇f(w)          // Calcular el gradiente

    // Paso 2:
    w_nuevo = w - α * g // Actualizar el punto

    // Paso 3: Preparar siguiente iteración
    w = w_nuevo
    k = k + 1
```

De acuerdo con el pseudoalgoritmo del Método de descenso de gradiente, en cada iteración se calcula el gradiente de la función evaluada en el punto actual w , y se actualiza de acuerdo con la regla $w - \alpha \nabla f(w)$.

Regresión logística

La regresión logística es una técnica que nos permite obtener un clasificador lineal binario. Considere un dato de entrada $x = [x_1, x_2] \in \mathbb{R}^2$, y sea $z = [x, 1]^T$. Sea $w = [w_1, w_2, w_3]^T$ el vector de parámetros del clasificador. La clasificación de este dato se realiza a través de la siguiente regla:

Si $w^T z = w_1 x_1 + w_2 x_2 + w_3 > 0$, entonces x es clasificado como un dato de clase 1

Si $w^T z = w_1 x_1 + w_2 x_2 + w_3 < 0$, entonces x es clasificado como un dato de clase 0.

La función que mide qué tan bueno es el clasificador con parámetros w para clasificar sobre m datos de entrenamiento (denominada función de pérdida) se define a través de la siguiente ecuación:

$$f(w) = -\frac{1}{m} \sum_{i=1}^m t_i \log y_i + (1 - t_i) \log(1 - y_i)$$

donde:

- $x^{(i)}$: i-ésimo dato de entrenamiento. Es un número real en este caso.
- $z^{(i)} = [x^{(i)}, 1]^T$.
- t_i : es la clase verdadera del i-ésimo dato de entrenamiento. Es 0 o 1.
- $y_i = \frac{1}{1+e^{-w^T z^{(i)}}}$ es la sigmoide o función logística.

Entre más pequeño el valor de $f(w)$, mejor es el w para definir la regla de clasificación. Es importante aclarar que la notación $x^{(i)}$ no significa que x esté "elevado" a la i . Es una forma de mostrar que ése es el i-ésimo dato x .

Se sabe que el gradiente de f está definido por:

$$\nabla f(w) = \frac{1}{m} \sum_{i=1}^m (y_i - t_i) z^{(i)}.$$

Implementación del método de descenso de gradiente para encontrar la recta separadora

Considere el archivo adjunto `breastCancer`. Esta es una base de datos real que contienen información sobre las características extraídas del núcleo de células epiteliales mamarias y otros atributos de células de mama, recolectadas a través del análisis de imágenes digitalizadas de biopsias de mama. Este conjunto de datos presenta **569 observaciones con 2 características** (features) cada una, que corresponden a medidas resultado del análisis de la imagen digital mamaria. Estas características corresponden a 2 propiedades que se calculan para cada núcleo de

célula observada en la imagen. La variable `pronostic` contiene las etiquetas de cada una de estas observaciones, donde 1 es si la muestra tiene malignidad, y 0 si no es una muestra maligna. Esta base de datos es la que contiene los $x^{(i)}$ con sus respectivos t_i para el entrenamiento del clasificador.

- a) Considere el problema de optimización

$$\begin{aligned} \min_w \quad & f(w) \\ \text{sujeto a } & w \in \mathbb{R}^3, \end{aligned}$$

donde $f(w)$ se construye partir de los datos en `breastCancer`. Implemente el algoritmo de descenso de gradiente para resolver este problema.

- b) Ejecute el algoritmo para diferentes valores de α y w_0 . Grafique $f(w)$ vs las iteraciones del algoritmo para observar la evolución del proceso de optimización. Grafique la recta separadora definida por w sobre el scatter plot de los datos.
- c) Implemente y ejecute el algoritmo de descenso de gradiente estocástico, y compárelo con el algoritmo implementado en b). Grafique $f(w)$ vs las iteraciones del algoritmo para observar la evolución del proceso de optimización. Grafique la recta separadora definida por w sobre el scatter plot de los datos.



Universidad de
los Andes

Colombia

© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
