

Histograma

Un histograma es una representación gráfica de la distribución de las observaciones de una variable aleatoria X . Usualmente se grafica a través de barras verticales, donde cada barra está asociada a un intervalo de x , y representa la frecuencia de aparición de valores dentro de ese intervalo en el conjunto de datos. Es una herramienta útil para aproximar la forma de la función de masa de probabilidad en el caso de las variables aleatorias discretas, o la función de densidad de probabilidad en el caso de las variables aleatorias continuas.

Construcción del histograma

Definición de los bins: Una vez se tienen las observaciones de la variable aleatoria X , se debe conocer el rango de los datos. Éste se puede conocer a través del valor mínimo **a** y el valor máximo **b** de las observaciones. El intervalo $[a, b]$ se parte en pedazos que llamamos *bins* (por su nombre en inglés). Cada *bin* es un intervalo, y todos los *bins* son mutuamente excluyentes y abarcan todo el rango de los datos. Es usual que el ancho de cada intervalo sea igual para todos los intervalos.

Cálculo de la frecuencia: Para cada *bin*, se debe contar cuántas veces aparecen las observaciones dentro de intervalo. Sea $[a_i, b_i]$ el intervalo asociado al i -ésimo bin. Sea N_i la cantidad de observaciones en el i -ésimo bin, y sea N la cantidad total de observaciones. A partir de esta información podemos obtener:

- La frecuencia relativa N_i/N , la cual nos da una aproximación de la probabilidad $P(X \in [a_i, b_i])$. Es decir,

$$P(X \in [a_i, b_i]) \approx \frac{N_i}{N}.$$

- Si X es una variable aleatoria continua, podemos tener una estimación de la densidad de probabilidad a través del histograma. Recordemos que

$$P(X \in [a_i, b_i]) = \int_{a_i}^{b_i} p(x) dx.$$

Si asumimos que $b_i - a_i$ es lo suficientemente pequeño, podemos aproximar esta integral de la siguiente forma:

$$P(X \in [a_i, b_i]) \approx p(a_i)(b_i - a_i).$$

Si despejamos $p(a_i)$, obtenemos:

$$p(a_i) \approx P(X \in [a_i, b_i]) \frac{1}{b_i - a_i}.$$

Como sabemos que $P(X \in [a_i, b_i]) \approx N_i/N$, entonces nos queda:

$$p(a_i) \approx \frac{N_i}{N} \frac{1}{b_i - a_i}.$$

A través de esto podemos tener una inspección visual de la forma de la **función de densidad de probabilidad** a partir del histograma. Esta forma de calcular el tamaño de las barras del histograma es muy útil cuando queremos sobreponer el histograma con la gráfica de la función de densidad de probabilidad que asumimos tiene la variable aleatoria X .

Ejemplo

Sea X una variable aleatoria gaussiana con valor esperado $E[X] = \mu = 5$ y varianza $E[(X - E[X])^2] = \sigma^2 = 0.09$. La Figura 1 muestra una gráfica de la función de densidad de probabilidad de esta función. Note que esta función toma valores que son superiores a 1, ya que NO es una probabilidad.






Figura 1. Gráfica de una función de densidad de probabilidad de una variable aleatoria Gaussiana con media 5 y varianza 0.09.


De esta variable aleatoria X generamos 500 muestras con las cuales podemos construir un histograma. En la siguiente figura observamos un histograma, donde las barras representan el conteo de las observaciones que se tienen en cada bin:




De igual forma podríamos graficar este histograma, ahora con una estimación de las probabilidades de que la variable X pertenezca a cada intervalo:



También podríamos graficar el histograma con las barras representando una aproximación de la función de densidad de probabilidad de X :



Con esta última podemos comparar directamente el histograma con la distribución real de la variable aleatoria:



Note que la única diferencia entre estos histogramas es la escala del eje vertical.



© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
