

Distribuciones conjuntas de múltiples variables

En Machine Learning usualmente modelamos experimentos donde hay múltiples variables aleatorias. Aquí vamos a presentar las funciones de distribución de probabilidad conjunta cuando hay múltiples variables, e introduciremos el concepto de covarianza como momento estadístico de este tipo de distribuciones.

Distribuciones conjuntas de variables discretas

Considere las variables aleatorias $X_1, X_2, \dots, X_n$, todas del mismo experimento aleatorio. La función de masa de probabilidad conjunta de estas variables aleatorias se define como:

$$p(x) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n),$$

donde $x = [x_1, x_2, \dots, x_n]^T$ son valores particulares de cada una de las variables aleatorias. Esta función de masa de probabilidad cuantifica la probabilidad de que, de forma simultánea, $X_1 = x_1, \text{ y } X_2 = x_2, \text{ y } \dots, \text{ y } \dots, X_n = x_n$. Aquí, se tiene que cumplir que $p(x) \geq 0$ para todo x , y

$$\sum_{x_1} \sum_{x_2} \dots \sum_{x_n} p(x) = 1.$$

Por ejemplo, considere dos variables aleatorias discretas X_1 y X_2 . La función de masa de probabilidad conjunta $p(x)$ está definida en la Figura 1.




Figura 1. Función de masa de probabilidad conjunta de X_1 y X_2 .

De acuerdo con esta figura, la función evaluada en $x = [2,4]^T$ es $1/20$, indicando que la probabilidad de que las variables X_1 y X_2 tomen valores 2 y 4 de forma simultánea es $1/20$. Note que si sumamos la probabilidad de todas las combinaciones de x_1 y x_2 , obtenemos 1.

Distribuciones conjuntas de variables continuas

Considere las variables aleatorias continuas $X_1, X_2, \dots, X_n$, todas del mismo experimento aleatorio. Sean $x = [x_1, x_2, \dots, x_n]^T$ valores particulares de cada una de las variables aleatorias, y sea $X = [X_1, X_2, \dots, X_n]^T$. La función de densidad de probabilidad conjunta de estas variables aleatorias $p(x)$ satisface:

$$P(X \in B) = \int_{x \in B} \int \cdots \int p(x) dx_1 dx_2 \cdots dx_n$$

donde B es una región de $\mathbb{R}^n$. Esto quiere decir que, la probabilidad de que las variables aleatorias estén dentro de la región B es volumen que está debajo de la función $p(x)$ en esa región particular. La función de densidad de probabilidad satisface $p(x) \geq 0$ y

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} p(x) dx_1 dx_2 \cdots dx_n = 1.$$

Por ejemplo, considere dos variables aleatorias continuas X_1 y X_2 cuya función de densidad de probabilidad está definida por:

$$p(x) = \begin{cases} 0.5 & \text{si } 1 \leq x_1 \leq 3, -1 \leq x_2 \leq 0 \\ 0 & \text{de lo contrario} \end{cases}.$$

Es decir, la factibilidad de ocurrencia de los valores alrededor de $x = [2, -0.5]^T$ es de 0.5. Este valor de 0.5 NO es una probabilidad. Es la densidad de probabilidad de $x = [2, -0.5]^T$. Note que el volumen debajo de $p(x)$ en todo $\mathbb{R}^2$ es 1.

Covarianza

Sean X_1 y X_2 dos variables aleatorias. La covarianza entre X_1 y X_2 se define como:

$$\text{cov}(X_1, X_2) = \mathbb{E}[(X_1 - \mathbb{E}[X_1])(X_2 - \mathbb{E}[X_2])].$$

Este es un momento estadístico que nos da una idea de la forma de la distribución de probabilidad conjunta de dos variables aleatorias (continuas o discretas). El signo de la covarianza nos muestra alguna tendencia en la relación lineal de las dos variables aleatorias: si es positivo, nos indica que valores altos en una de las variables están asociados a valores altos en la otra; si es negativo, nos indica que valores altos en una de las variables están asociados a valores bajos en la otra. Dos variables se dice que son **no correlacionadas** si $\text{cov}(X_1, X_2) = 0$.

La correlación o coeficiente de Pearson está definido como

$$\rho(X_1, X_2) = \frac{\text{cov}(X_1, X_2)}{\sqrt{\text{var}(X_1)\text{var}(X_2)}},$$

donde $\text{var}(X_1)$ se refiere a la varianza de la variable aleatoria. Se puede demostrar que $|\text{cov}(X_1, X_2)| \leq \sqrt{\text{var}(X_1)\text{var}(X_2)}$, lo cual implica que $\rho(X_1, X_2) \in [-1, 1]$. Este coeficiente se puede ver como una versión escalada de la covarianza.

Sean $x_1^{(i)}$ y $x_2^{(i)}$ las i -ésimas observaciones de las variables aleatorias X_1 y X_2 , y sean μ_1 y μ_2 las estimaciones de sus valores esperados. Un estimador de la covarianza es:

$$\text{cov}(X_1, x_2) = \frac{1}{N-1} \sum_{i=1}^N (x_1^{(i)} - \mu_1)(x_2^{(i)} - \mu_2),$$

siendo N la cantidad de observaciones que se tienen.



© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
